

HelixLLM

HelixLLM

من حاسوبك Anthropic و OpenAI ثنائي واحد، ستة أوضاع — استدلال متوافق مع المحمول إلى مجموعة متعددة المضيفين.

الملخص

ثنائي واحد بنظام Go: موزّع على مستوى المؤسسات مبنيّ على LLM هو نظام HelixLLM أوضاع يتدرّج من التطوير أحادي المضيف إلى الإنتاج متعدد المضيفين. يقدّم واجهات برمجة تطبيقات مع استدلال محلي باستخدام HTTP/3 عبر Anthropic و OpenAI متوافقة بالكامل مع ReAct ونظام وكيل، RAG وسلسلة احتياطية متعددة المزودين مُقيّمة، وخط أنابيب llama.cpp.

وصف مختصر

يعرض واجهات برمجة تطبيقات متوافقة Go. موزّع ثنائي مبنيّ على LLM هو نظام HelixLLM llama.cpp ويشغل استدلالاً محلياً باستخدام HTTP/3 عبر Anthropic و OpenAI مع ويكتشف تلقائياً ويقيّم مزودي الخدمات السحابية المجانية ضمن سلسلة احتياطية، ويضيف خط أنابيب القادر على استدعاء الأنواع — قابل للنشر في ستة أوضاع ReAct بالإضافة إلى وكيل RAG معرفية مختلفة.

وصف مفصّل

وحيلته، Gin و Go موزّع على مستوى المؤسسات، مبنيّ باستخدام LLM هو نظام HelixLLM الأساسية تكمن في أن قطعة برمجية واحدة تخدم جميع المستويات. يُترجم إلى ثنائي واحد يحدد نظام للحصول على مثال شامل على حاسوب محمول full الأوضاع عند النشر ماهية هذا الثنائي: شغله ك موزّعة على control و knowledge agents و brain و gateway أو وّزع المسؤوليات عبر أوضاع عدة مضيفين — نفس الكود يعاد ترتيبه دون إعادة كتابته، من جهاز المطور إلى مجموعة الإنتاج.

OpenAI يتقن النظام لغتين بطلافتها: واجهات برمجة تطبيقات متوافقة بالكامل مع الحالية من كلا النظامين دون تعديل، وكلها تُقدّم عبر SDK بحيث تعمل عملاء Anthropic، يعمل الاستدلال المحلي TLS 1.3 ودعم HTTP/2 مع احتياطي تلقائي لـ HTTP/3 (QUIC) بحيث يسرّع نفس البناء على أجهزة ROCm و Metal و CUDA مع دعم llama.cpp عبر على حد سواء. أما الميزة البارزة فهي سلسلة الاحتياطية متعددة AMD و Apple و Nvidia المزودين، التي تحول عدم موثوقية الاستدلال السحابي المجاني إلى مورد مُدار وقادر على الشفاء الذاتي: Chutes. تلقائياً النماذج المجانية من أكثر من 7 مزودي خدمات سحابية HelixLLM يكتشف.

OpenRouter. HuggingFace. Nvidia. Cerebras. SambaNova. Together). ووجه الطلبات عبر السلسلة المرتبة مع LLMsVerifier وقيمتها عبر (llama.cpp مع ضمان استخدام — xx احتياطي تلقائي للأخطاء 429/5 المحلي كملاذ أخير، بحيث لا يفشل الطلب أبداً لعدم توفر مزود

منصة تطبيقات كاملة: يتضمن خط أنابيب معرفية HelixLLM بالإضافة إلى الاستدلال الخام، يُعد مع استدعاء الأبحاث ReAct ونظام وكيل (vector استيعاب، تجزئة، تضمين، بحث) RAG ضمن نفس الثنائي. يُؤتي نظام الأوضاع ثمره أيضاً على مستوى RAG وجلسات المحادثة، وتكامل المباشرة داخل العملية دون Go تتواصل جميع الطبقات عبر استدعاءات full الاتصال — ففي وضع SSE و gRPC أي عبء شبكي، بينما ينسّق الثنائي المتطابق عند توزيعه على عدة مضيفين عبر الذي يتطابق مع تنسيقات SSE وبث Brotli/gzip ويكمل النظام بمفاوضات المحتوى Kafka. مع تحديد المعدل، ومقاييس JWT و API-key بايتاً ببايت، ومصادقة Anthropic و OpenAI للبنية التحتية Go ومجموعة كبيرة من وحدات، OpenTelemetry، وتتبع Prometheus، الإنتاجية.

المحتوى

لماذا قمنا ببنائه

تحتاج الفرق إلى استدلال قابل للنقل ومتوافق مع المعايير ومرن — دون الحاجة إلى إعادة كتابة بحيث يمكن لنفس الملف التنفيذي HelixLLM العملاء أو الارتهاان بمزود واحد أو جهاز واحد. تم بناء أن يعمل محلياً للتطوير ويتوسع ليشمل مجموعة إنتاجية متعددة المضيفين، ويتحدث لهجات OpenAI و Anthropic التي يستخدمها العملاء بالفعل.

لماذا يُعد ثورة في المجال

، إنه يدمج مجموعة كاملة من بنية الاستدلال — البوابة، والاستدلال المحلي، والعودة إلى السحابة والوكلاء — في ملف تنفيذي واحد يتحكم فيه مفتاح وضع التشغيل، بحيث يصبح قرار نشر RAG، البنية المعمارية قراراً يتم اتخاذه في وقت التشغيل بدلاً من أن يكون مشروع إعادة منصة. كما يحول ما كان يُعد نقطة ضعف إلى ميزة: تصبح موثوقية مزودي السحابة أولوية رئيسية تُقاس باستمرار، وتُدار من خلال سلسلة عودة ذاتية الإصلاح تُقيّم المزودين كل بضع دقائق وتتحول دائماً إلى الاستدلال المحلي المضمون. الإمكانية التي يتيحها هي نقطة نهاية واحدة يمكنك الاعتماد عليها حقاً — متوافقة مع المعايير، قابلة للنقل من الحاسوب المحمول إلى المجموعة، وغير قاهرة على التوقف عن العمل لأن أحد المزودين الرئيسيين قد فرض قيوداً على المعدل أو فشل.

ما الجديد في هذا الحل

- — ملف تنفيذي واحد بنظام مكون من ستة أوضاع يعمل إما بشكل متكامل أو كأدوار موزعة — عند الفصل gRPC/SSE/Kafka و full المباشرة داخل العملية في وضع Go مكالمات بحيث تتغير طوبولوجيا النشر دون تغيير في الكود أو فرض ضرائب شبكية غير مطلوبة.
- سلسلة عودة متعددة المزودين مكتشفة تلقائياً ومقيمة عبر أكثر من 7 مزودين مجانيين، تُصنّف و ضمان استخدام xx مع تجاوز تلقائي لأخطاء 429/5 LLMsVerifier باستمرار بواسطة كملاذ أخير — تحويل قرة الطبقة المجانية إلى قرة موثوقة llama.cpp.
- مع عودة تلقائية HTTP/3 تُقدّم عبر Anthropic و OpenAI واجهات متوافقة مع كل من بحيث يتصل العملاء من أي من النظامين البيئيين دون تعديل، HTTP/2 إلى

- من قاعدة كود واحدة — نفس الإصدار ROCm وMetal وCUDA استدلال محلي يشمل AMD وApple وNvidia يعمل بتسريع على أجهزة

أكبر التحديات التقنية وكيف تغلبنا عليها

- تفرض معظم الأنظمة حداً صلباً بين .التوسع من مضيف واحد إلى عدة مضيفين دون إعادة كتابة التطوير المحلي ”و” الإنتاج الموزع“، وعبر هذا الحد يتطلب إعادة هيكلة. لقد ألغينا هذا الحد بنظام“ أوضاع على ملف تنفيذي واحد: تتواصل نفس الطبقات عبر مكالمات مباشرة داخل العملية في عبر الأوضاع الموزعة، بحيث يصبح gRPC/SSE/Kafka وتتحول بسلاسة إلى full وضع .التوسع مجرد تغيير في التكوين بدلاً من نقل
- الاستدلال في الطبقة المجانية .مزودو السحابة المجانيون غير الموثوقين والمحدودي المعدل سريع حتى يفرض قيوداً على المعدل أو يختفي أثناء الطلب. جعلناه موثقاً باكتشاف النماذج وتتبع رؤوس قيود المعدل بشكل استباقي، LLMsVerifier المتاحة تلقائياً، وتقييمها باستخدام لتوجيه الطلبات بعيداً عن المزودين على وشك التقييد، والعودة تلقائياً عبر السلسلة المصنفة إلى المحلي — بحيث لا تصل تقلبات المجموعة أبداً إلى المتصل llama.cpp
- إعادة كتابة العملاء لاعتماد خلفية استدلال جديدة أمر غير .توافق العملاء عبر نظامين بيئيين وصولاً إلى — Anthropic وOpenAI لكل من API مقبول. لقد قمنا بتنفيذ أشكال المختلفة الخاصة بكل منهما — بحيث تشير مجموعات تطوير البرمجيات SSE تنسيقات بث وتعمل ببساطة HelixLLM من أي من المعسكرين إلى

المحتوى

مجموعة الأدوات التقنية

- اختيرت لأن بيئة التشغيل ذات الملف الثنائي الواحد والموجهة نحو التوازي — Go + Gin هي ما يجعل نظام الأوضاع بأكمله ممكناً: بناء واحد يمكن أن يكون خادماً محلياً أو دوراً ضمن الخاصة بالبوابة HTTP مجموعة خوادم. تحمل النظام بأكمله بالإضافة إلى طبقة
- اختيرت — HTTP/2 مع الرجوع التلقائي إلى TLS 1.3، HTTP/3 (QUIC) + نقل البيانات الحديث منخفض الكمون والمرن في الاتصالات، وتعرض كواجهة الخادم مع التفاوض HTTP/2. بهدوء إلى QUIC التلقائي بحيث تعود العملاء غير القادرين على استخدام
- اختيرت للاستدلال المحلي المحمول — llama.cpp (CUDA/Metal/ROCm) من قاعدة برمجية واحدة؛ كما تعمل AMD وApple وNvidia الذي يتسارع عبر منصات كخيار احتياطي مضمون يمنع سلسلة التراجع من الوصول إلى طريق مسدود
- اختيرت لتحويل “أي مزود جيد الآن” إلى رقم؛ حيث تقوم بتقييم LLMsVerifier وترتيب سلسلة التراجع السحابية كل خمس دقائق بحيث تتبع التوجيه الجودة الحية بدلاً من الافتراضات القديمة
- اختيروا لاستغلال السعة — (Chutes, OpenRouter, HuggingFace, Nvidia, Cerebras, SambaNova, Together) موفرو الخدمات السحابية المجانية عبر عدة مصادر؛ حيث يتم اكتشافهم وترتيبهم تلقائياً في سلسلة تراجع واحدة بحيث لا يشكل أي مزود نقطة فشل واحدة
- اختيروا كوسائط نقل بين الأوضاع للنشر الموزع — gRPC + SSE + Kafka لتدقق الأحداث المفككة بين الأنوار Kafka للبلبث المباشر، و SSE للمكالمات بين الخدمات، و من البداية إلى RAG اختير لتشغيل خط المعرفة — embeddings / مخزن المتجهات .النهاية: استيعاب، تقطيع، تضمين، والبحث في المستندات التي تدعم إجابات النموذج
- اختير لقياس الأداء وتتبع الطلبات الموزعة — Prometheus + OpenTelemetry عبر أي أوضاع يتم نشرها

- اختيرت لإعادة استخدام المكونات الأساسية — **vasic-digital** الفرعية من **Go** وحدات للبنية التحتية الإنتاجية المجربة بدلاً من إعادة بنائها، مما يحافظ على اتساق أساس النظام مع المجموعة التقنية الأوسع.

ملاحظات الحالة والفرآهة

- نظام استدلال موزع وظيفي قيد التطوير النشط. **الحالة: تجريبية**
- (فارغ licenseInfo) المستودع لا يعلن عن رخصة في بيانات التعريف. **الرخصة: لم تُحدد بعد** — هذا الأمر غير مُتحقق منه ويجب حله قبل تحديد الرخصة —
- : بينما يعيد github.com/HelixDevelopment/llm المستودع المرجعي حاليًا يشير إلى التوجيه إليه. أرقام عتبات التغطية وعدد الوحدات الفرعية في ملف HelixLLM مسار README هي بيانات ذاتية التقرير

أساسية-Helix: درجة الأولوية