

LLMProvider

LLMProvider

واجهة واحدة، 43 مزودًا — مع قواطع دوائر، وإعادة المحاولة، ومراقبة الصحة مدمجة

المُلخَص

الموحدة LLMProvider عامة وقابلة لإعادة الاستخدام تحدد واجهة Go هو وحدة LLMProvider بالإضافة إلى أنماط المرونة الإنتاجية المحيطة بها — قاطع الدائرة، ومراقبة الصحة، وإعادة المحاولة مع التراجع التدريجي، والتحميل الكسول — وتوفر 43 تنفيذًا ملموسًا للمزودين خلف عقد واحد، مع محول ونموذج اكتشاف نماذج صادق دون أي حلول احتياطية مشفرة مسبقًا OpenAI عام متوافق مع

الوصف المختصر

Complete،) الواحدة LLMProvider قابلة لإعادة الاستخدام تعرض واجهة Go وحدة بالإضافة إلى (CompleteStream، HealthCheck، GetCapabilities، ValidateConfig) بدائيات تحمل الأخطاء — قاطع الدائرة، ومراقب الصحة، وإعادة المحاولة مع تراجع تدريجي مضاف إليه OpenAI. آمنة. OpenAI. تذبذب زمني، والتحميل الكسول — عبر 43 محولًا للمزودين ومحول عام متوافق مع للخيوط.

الوصف الطويل

لكنها نادرًا ما تُبنى LLM هي طبقة التجريد التي يحتاجها كل خدمة مستهلكة لـ LLMProvider بشكل جيد — تلك البنية التحتية غير الجذابة التي تفصل بين العرض التوضيحي والنظام الذي ينجو من Complete، — مواجهة حركة المرور الحقيقية. فهي تحدد واجهة واحدة مكرمة للقرارات بحيث — CompleteStream، HealthCheck، GetCapabilities، ValidateConfig يستهدف كود التطبيق عقدًا واحدًا بالضبط بغض النظر عن أي من الـ 43 خلفية يجيب على الاستدعاء، ثم توفر التعزيزات التشغيلية التي تحول مكالمات المزودين الهشة إلى شيء يمكنك تشغيله في الإنتاج دون حبس أنفاسك. قاطع الدائرة ثلاثي الحالات (مغلق → مفتوح → نصف مفتوح) يغلف أي مزود حيث يُحسب الدفع الفارغ بشكل صحيح كفشل — بحيث، بما في ذلك قناته البثية — بشكل شفاف يمكن لخلفية واحدة سيئة السلوك أن تفتح القاطع وتمنع انهيار الخدمة بأكملها؛ ويدير المركزي كل القواطع دفعة واحدة. مراقب الصحة القابل للتكوين يتابع CircuitBreakerManager، المزودين باستمرار عبر حالات الصحة/التدهور/الخلل/المجهول بناءً على فحوصات العتبات والفترات بحيث يُلاحظ التدهور بدلاً من اكتشافه عند حدوث انقطاع. منطلق إعادة المحاولة يضيف التراجع الأسّي مع التذبذب الزمني في الأعلى، متخذًا قرارات مكرمة للحالة — إعادة المحاولة للأخطاء التي تستحق أو سياق XX دون إهدار الدورات على أخطاء 4، (أعطال الشبكة العابرة، 429xx، 5) إعادة المحاولة

ملغى — مع تأخير محدد بحيث لا يمكن لعاصفة التراجع أن تخرج عن السيطرة. ونمط التحميل الكسول يؤجل بناء كل مزود حتى استخدامه الفعلي الأول — وهو خيار تصميم متعمد يجعل تسجيل جميع المزودين الـ 43 مجانيًا بشكل أساسي.

ينفذ الواجهة OpenAI متوافق مع generic توفر الوحدة 43 حزمة مزود ملموسة بالإضافة إلى محول مع SSE وبث، Bearer مصادقة — `/v1/chat/completions` نقطة نهاية أي الكاملة ضد بحيث يصبح المزود الذي ليس لديه حزمة مخصصة مواطنًا من الدرجة — [DONE] معالجة صحيحة لـ الخاص به. تُحل بيانات الاعتماد في مكان واحد بالضبط URL الأولى بمجرد توجيه المحول إلى مما يغلق فئة الأخطاء الكاملة التي، (`ApiKey_<Provider>` باستخدام اصطلاح صارم، `apikeys`) تقول “المفتاح المشفر يجتاز مجموعة الاختبارات، لكن المفتاح الحقيقي لم يُربط أبدًا، ويتعطل المنتج في الإنتاج” من مصرها. اكتشاف النماذج متعمد وصارم في صدقه: فهو يستعلم واجهات برمجة التطبيقات للمزودين الفعليين خلف ذاكرة تخزين مؤقتة ذات مدة حياة، و— وفقًا للحكومة — تم حذف طبقة الحل أي `LLMProvider` الاحتياطي المشفرة مسبقًا بالكامل. عندما يفشل الاكتشاف الفعلي، لا تُرجع بدلاً من كتالوج قديم، بحيث لا يُعطى المتصل مطلقًا معرف نموذج يبدو صالحًا ثم لا يمكن شيء، استدعاؤه. كل جزء من هذا البناء آمن للخيوط للاستخدام المتزامن.

المحتوى

لماذا أنشأناها

في بيئة الإنتاج — حيث تفرض مقدمو الخدمة قيودًا على LLM تفشل المكالمات البسيطة لـ المعدلات، أو تتدهور الخدمة، أو تتوقف تمامًا، وقد يتسبب مزود واحد سيئ في إسقاط الخدمة بأكملها. `LLMProvider` تتغير فهارس النماذج، وتقدم القوائم المشفرة مسبقًا معرفات لم تعد صالحة. تجمع بين الواجهة ومرونة الأداء والاكتشاف الصادق بحيث يرث كل مستهلك القمرة على التحمل والموثوقية تلقائيًا دون جهد إضافي.

لماذا تُعد نقلة نوعية

إلى خطوة واحدة فقط — إما تنفيذ واجهة واحدة، أو توجيه المحول “LLM” تختزل عملية “دمج مزود العام إلى نقطة نهاية — ثم تغلف هذا المزود تلقائيًا وشفافًا في قواطع الدوائر ومراقبة الصحة وإعادة المحاولة مع تأخير متذبذب. تتوقف المرونة عن كونها شيئًا يعيد كل فريق اختراعه (بشكل سيئ، وتحت ضغط المواعيد النهائية، بعد أول انقطاع) لتصبح السلوك الافتراضي للمكتبة عبر جميع مزودي الخدمة البالغ عددهم ٤٣ مزودًا. تُكتب هندسة الموثوقية مرة واحدة، وتُختبر بدقة، ويرثها الجميع مجانيًا بمجرد استيرادها.

ما الجديد في الابتكار

- دمج الاستكمال والبث ومراقبة الصحة والتحقق من القمرات والتكوين — واجهة واحدة تدرك القمرات في عقد واحد تلتزم به جميع الخلفيات بنفس الطريقة.
- `CompleteStream` يحمي القاطع قناة. التغليف الشفاف لقواطع الدوائر — بما في ذلك البث — وليس مجرد طلب/استجابة فحسب، ويعامل البث الفارغ على أنه الفشل الحقيقي الذي يمثله مع إشعارات المستمعين الآمنة من التعطل وخارج القفل.
- تبقى الحزم المخصصة خفيفة، وأي — **OpenAI ٤٣** حزمة مزودات + محول عام متوافق مع يعمل على الفور بمجرد توجيه المحول `/v1/chat/completions` بأعلى غير مدرج يتحدث إليه.

- مكان واحد فقط يقرأ متغيرات البيئة — **(apikey)** سلطة اعتماد واحدة مما يلغي بشكل هيكلي عدم التطابق بين “الاختبارات الناجحة والمنتج، ApiKey_<Provider>، المعطل” بدلاً من مجرد التحذير منه.
- واجهات برمجة التطبيقات الحية للمزودين — اكتشاف صادق للنماذج (دون احتياطي مشفر) ولا تقدم أبداً فهرساً قديماً أو nil، خلف ذاكرة تخزين مؤقتة ذات مدة صلاحية؛ عند الفشل، تُرجع مُختلفاً يمنح معرفات غير قابلة للاستدعاء.
- يُؤجل البناء إلى أول استخدام، لذا فإن تسجيل — **sync.Once** التهيئة الكسولة باستخدام جميع المزودات البالغ عددها ٤٣ مزوداً لا يكلف شيئاً تقريباً حتى يتم استدعاء أحدهما فعلياً.
- أداة تشغيل حقيقية تختبر سلوك قواطع الحوائ — مكدس تحدي متعدد اللغات ومقاوم للخداع والصحة وإعادة المحاولة عبر خمس لغات، محكمة باختبار الطفرات المزود (يجب أن يخرج الكود غير المتحور بصفر؛ ويجب أن يفرض الطفر المحقون الخروج برقم ٩٩)، لذا فإن المجموعة الناجحة تعني سلوكاً يعمل بشكل مؤكد.

أكبر التحديات التقنية وكيف تغلبنا عليها

- يجب ألا يسحب مزود واحد غير مستقر خدمة بأكملها معه. تم حل هذه. فشل المزودات المتتالي المشكلة باستخدام قاطع حوائ ثلاثي الحالات (مغلق → مفتوح → نصف مفتوح) يغلف أي مزود بشكل شفاف، ويفتح عند الفشل المستمر، ويتحقق من التعافي في الحالة نصف المفتوحة وبثه، CircuitBreakerManager ويتم تنسيقه مركزياً بواسطة.
- — تم حلها باستخدام تأخير أسّي حساس للحالة مع تذبذب. الأخطاء العابرة وحدود المعدلات بحيث $\min(\text{InitialDelay} \cdot \text{Multiplier}^{(n-1)}, \text{MaxDelay}) \pm \text{jitter}$ تنتشر محاولات إعادة المحاولة بدلاً من التزامن في قطيع مدو. يعيد المحاولة بالضبط لما يجب إعادة المحاولة له (٤٢٩، ٥٠٠، ٥٠٢، ٥٠٣، ٥٠٤، وأخطاء الشبكة)، ويرفض إهدار المحاولات على آخر XX سياق ملغى أو أي خطأ من فئة ٤.
- مع تسجيل ٤٣ مزوداً ولكن. التوسع مع العديد من المزودات المسجلة وغير المستخدمة استخدام عدد قليل منها فقط في أي خدمة معينة، فإن البناء المتسرع سيكون هراً خالفاً. تم حل بحيث لا تدفع المزودات التي، sync.Once هذه المشكلة بالتهيئة الكسولة المحروسة بواسطة. تستدعيها فعلياً سوى تكلفة إعدادها.
- تم حل هذه المشكلة بحذف طبقة الاحتياطي المكتشفة مسبقاً. منح معرفات نماذج غير صالحة وعدم إرجاع أي شيء عند فشل الاكتشاف المباشر — بالإضافة (CONST-036 وفقاً لـ) بالكامل إلى نسخة دفاعية عند الإرجاع بحيث لا يتمكن المتصل من تعديل ذاكرة التخزين المؤقت أو التنافس مع قارئ آخر. تُفرض الصدق هيكلياً، وليس بالاتفاق.
- يتمثل نمط الفشل الخفي في حدوث تعطل بين قفل القاطع واستدعاءات. البث وصحة التزامن المستمعين. تم حل هذه المشكلة بالتقاط لقطات من المستمعين وإخطارهم خارج القفل ضمن مهلة زمنية مدتها ٥ ثوانٍ، وفك القفل قبل الإخطار عند إعادة الضبط — مع بناء كل مكون للاستخدام race - التزامن واختباره بواسطة مجموعة.

المحتوى

مجموعة الأدوات التقنية

- **Go (1.25.3)** — تم اختياره لقرته المتميزة على التوازي، والثنائيات الثابتة، ومكتبته القياسية القوية؛ حيث يحمل الوحدة، والواجهة، وكل أدوات المرونة، وجميع المحولات البالغ عددها ٤٣.
- **net/http** (مكتبة قياسية) — HTTP بروتوكول خالٍ من التبعيات عن قصد: يدعم عملاء OpenAI المزودين لكل مزود، والمحول المتوافق مع واستدعاءات الاكتشاف المباشرة، فلا توجد OpenAI المزودين لكل مزود، والمحول المتوافق مع طبقة نقل خارجية تحتاج إلى تدقيق أو تصحيح.

- **logrus** — تسجيل منظم ومدرّك للمستويات حيث يحتاج المشغلون إلى وضوح الرؤية: داخل
- **testify** — يدير مجموعة الاختبارات، والأهم من ذلك، تثبيت الفروع المتحوّلة الذي يجعل نجاح التشغيل ذا معنى حقيقي.
- **yaml.v3** — يحلّل حزم التدويل والإعدادات بتنسيق يبقى قابلاً للتحرير البشري
- **digital.vasic.models** — LLMRequest / LLMResponse / ProviderCapabilities الأنواع المشتركة محفوظة في مكان واحد بحيث يتحدّث كل محول بنفس المفردات (تبعية تشغيل موثقة)
- **circuit, health, retry, apikeys, discovery, providers/ (٤٣)** — حزم داخلية سطح المرونة والتكامل مقسم إلى وحدات صغيرة قابلة للاختبار: il8n، generic + بائعاً بشكل مستقل بدلاً من كونه كتلة واحدة ضخمة
- **.env + ~/api_keys.sh (اتفاقية ApiKey_<Provider>)** — مصدر واحد لا لبس فيه للحقيقة المتعلقة بالمصادقة، بحيث يتم توصيل المفاتيح بنفس الطريقة في الاختبارات وفي الإنتاج
- **العمود — مشغل التحدي + (-race -p 1)** — للاختبار المتزامن **Makefile** مجموعة أوامر الفقري لمكافحة الخداع: يكتشف كاشف السباق صحة التوازي، بينما يضرب مشغل التحدي السلوك الحقيقي عبر الفوضى، وهجمات الحرمان من الخدمة، والتوسع، والضغط، واكتشاف الخدمات المباشرة، وسيناريوهات عدم التعليق

ملاحظات الحالة والشفافية

- عام GitHub وحدة قابلة لإعادة الاستخدام ومستقلة؛ مستودع، الحالة: تجريبية
- بينما يوجد ملف MIT إلى رخصة doc.go غير متسقة — يشير. الرخصة: لم تُحدد بعد
- تحقّق قبل النشر — Apache-2.0 بنمط رخصة LICENSE
- LLMsVerifier هو المصدر الرئيسي الموثوق به لكاتالوج النماذج القياسي. يبدو ملف البيان helix-deps.yaml بينما تذكر الوثائق وجود تبعية لـ [] deps: قديماً (يعلن digital.vasic.models المستوى الثاني) (models.dev)؛ “المستوى الثاني” كعنصر نائب، وليس نشطاً بعد

للبنية التحتية — وحدة قابلة لإعادة الاستخدام LLM رئيسي (مجموعة Helix: مستوى الأولوية HelixTrack ومستقلة). يأتي في المرتبة التالية بعد