

HelixLLM

HelixLLM

از لپ‌تاپ تا کلاستر **OpenAI** و **Anthropic** یک باینری، شش حالت — استنتاج سازگار با چند میزبان.

خلاصه

ساخته شده Go در سطح سازمانی است که بر پایه LLM یک سیستم توزیع شده HelixLLM است: یک باینری واحد با سیستمی از حالت‌ها که از توسعه تک‌میزبان تا تولید چندمیزبان مقیاس‌پذیر را از طریق **OpenAI** و **Anthropic** است. این سیستم رابط‌های برنامه‌نویسی کاملاً سازگار با زنجیره جایگزین چندرأئه‌دهنده با llama.cpp ارائه می‌دهد، با استنتاج محلی HTTP/3 **ReAct** و سیستم عامل **RAG** امتیازدهی، پایپ‌لاین

توضیح کوتاه

است. این سیستم رابط‌های Go تک‌باینری و مبتنی بر LLM یک سیستم توزیع شده HelixLLM است، در دسترس قرار می‌دهد HTTP/3 را از طریق **OpenAI** و **Anthropic** برنامه‌نویسی سازگار با اجرا می‌کند، ارائه‌دهندگان ابری رایگان را به‌طور خودکار شناسایی و llama.cpp استنتاج محلی به همراه **RAG** امتیازدهی کرده و در زنجیره جایگزین قرار می‌دهد، و علاوه بر این، پایپ‌لاین دانش با قابلیت فراخوانی ابزار را اضافه می‌کند — قابل استقرار در شش حالت مختلف **ReAct** عامل

توضیح مفصل

ساخته شده و Gin و Go در سطح سازمانی است که با LLM یک سیستم توزیع شده HelixLLM ترند اصلی آن این است که یک مصنوع واحد برای تمام مقیاس‌ها خدمت‌رسانی می‌کند. این سیستم به یک باینری واحد کامپایل می‌شود که سیستم حالت‌های آن در زمان استقرار تصمیم می‌گیرد این باینری برای نمونه‌ای همه‌کاره روی لپ‌تاپ اجرا کنید، یا مسئولیت‌ها full چه نقشی ایفا کند: آن را به صورت تقسیم کرده و روی چندین control و gateway، brain، knowledge، agents بین حالت‌های میزبان توزیع کنید — همان‌کد، با چالش متفاوت به جای برنامه‌نویسی، از دستگاه توسعه‌دهنده تا کلاستر تولیدی.

و **OpenAI** این سیستم به دو گویش مسلط است: رابط‌های برنامه‌نویسی کاملاً سازگار با موجود از هر دو اکوسیستم بدون تغییر کار می‌کنند SDK به طوری که کلاینت‌های **Anthropic** نسخه ۱.۳ ارائه TLS و HTTP/2 با بازگشت خودکار به HTTP/3 (QUIC) همه از طریق **ROCm** و **CUDA**، پشتیبانی از llama.cpp می‌شوند. استنتاج محلی از طریق

انجام می‌شود، بنابراین همان بیلد روی سخت‌افزارهای انویدیا، اپل و ای‌ام‌دی به‌طور یکسان شتاب می‌گیرد. ویژگی برجسته آن زنجیره جایگزین چندرأئه‌دهنده است که ناپایداری معروف استنتاج ابری به‌طور خودکار مدل‌های HelixLLM را به منبعی مدیریت‌شده و خودترمیم‌شونده تبدیل می‌کند (Chutes، OpenRouter، HuggingFace، Nvidia، Cerebras، SambaNova، Together) را به‌طور خودکار از ۷ ارائه‌دهنده ابری شناسایی می‌کند، هر ۵ دقیقه آن‌ها را از llama.cpp هدایت می‌کند — همیشه با xx خودکار خطاهای ۴۲۹/۵ امتیازدهی کرده و درخواست‌ها را از طریق زنجیره رتبه‌بندی‌شده با جایگزینی LLMsVerifier طریق محلی به عنوان آخرین راهکار llama.cpp هدایت می‌کند — همیشه با xx خودکار خطاهای ۴۲۹/۵ تضمین‌شده، به طوری که هیچ درخواستی صرفاً به دلیل عدم دسترسی به ارائه‌دهنده شکست نخورد.

جذب (RAG) یک پلتفرم کامل کاربردی است: پایپ‌لاین دانش HelixLLM، فراتر از استنتاج خام با قابلیت فراخوانی ابزار، جلسات ReAct و سیستم عامل (vector قطعه‌بندی، تعبیه، جستجوی در همان باینری گنجانده شده‌اند. سیستم حالت‌ها در سطح شبکه نیز RAG مکالمه و یکپارچگی با سر بار Go تمام لایه‌ها از طریق فراخوانی‌های مستقیم درون‌فرایندی full سودمند است — در حالت شبکه صفر ارتباط برقرار می‌کنند، در حالی که همان باینری، زمانی که روی میزبان‌های مختلف توزیع Brotli/ هم‌هنگ می‌شود. در پایان، مذاکره محتوا با Kafka و SSE، gRPC می‌شود، از طریق بایت‌به‌بایت مطابقت دارد، احراز Anthropic و OpenAI که با فرمت‌های SSE استریم، gzip، ردیابی Prometheus، همراه با محدودیت نرخ، معیل‌های JWT و API هویت با کلید تکمیل‌کننده این Go و مجموعه بزرگی از زیرمأژول‌های زیرساختی تولید OpenTelemetry سیستم هستند.

محتوا

چرا آن را ساختیم

تیم‌ها به استنتاجی نیاز دارند که قابل حمل، سازگار با استانداردها و مقاوم باشد — بدون نیاز به بلزنویسی به گونه‌ای طراحی شد که HelixLLM. کلاینت‌ها یا وابستگی به یک ارائه‌دهنده یا یک ماشین خاص همان باینری بتواند به صورت محلی برای توسعه اجرا شود و در عین حال به یک خوشه تولیدی چند که کلاینت‌ها از پیش استفاده Anthropic و OpenAI میزبان مقیاس‌پذیر باشد، و با گویش‌های می‌کنند، ارتباط برقرار کند.

چرا یک تغییردهنده بازی است

و عامل‌ها را در یک RAG، این ابزار کل پشته استنتاج — مرگه، استنتاج محلی، بازگشت به ابر باینری واحد فشرده می‌کند که با یک کلید حالت کنترل می‌شود، به طوری که معماری‌ای که مستقر می‌کنید یک تصمیم‌زمان اجرا است نه یک پروژه بازطراحی پلتفرم. و چیزی را که پیش‌تر یک نقطه ضعف بود به یک قابلیت تبدیل می‌کند: قابلیت اطمینان ارائه‌دهندگان ابری به یک دغدغه درجه یک و پیوسته اندازه‌گیری‌شده بدل می‌شود که توسط زنجیره‌ای خودترمیم‌شونده و امتیازدهی‌شده مدیریت می‌شود؛ زنجیره‌ای که هر چند دقیقه یک بار ارائه‌دهندگان را دوباره رتبه‌بندی می‌کند و همواره به استنتاج محلی تضمین‌شده تنزل می‌یابد. قابلیتی که این امر آزاد می‌کند، یک نقطه پایانی واحد است که واقعاً می‌توانید به آن تکیه کنید — سازگار با استانداردها، قابل حمل از لپ‌تاپ تا خوشه، و ناتوان از خاموشی. به دلیل محدودیت نرخ یا شکست یک ارائه‌دهنده بالادستی.

نوآوری‌ها

- یک باینری واحد با سیستمی شش‌حالت که به صورت یکپارچه یا در نقش‌های توزیع‌شده اجرا می‌شود — gRPC/SSE/Kafka و full درون‌فرایندی در حالت Go می‌شود — فراخوانی‌های مستقیم

در حالت‌های توزیع‌شده—به طوری که توپولوژی استقرار بدون تغییر کد یا هزینه‌های شبکه‌ای ناخواسته تغییر می‌کند.

- زنجیره‌ای خودکشف‌شونده و امتیازدهی‌شده از ارائه‌دهندگان چندگانه با بیش از ۷ ارائه‌دهنده رایگان رتبه‌بندی می‌شوند، با شکست خودکار در برابر LLMsVerifier که به طور پیوسته توسط به عنوان آخرین راهکار—تبدیل llama.cpp و بازگشت تضمین‌شده به xx خطاهای ۴۲۹/۵ ظرفیت لایه رایگان به ظرفیتی قابل اعتماد.
- ارائه HTTP/3 که از طریق Anthropic و OpenAI سطوح سازگار با هر دو استاندارد به طوری که کلاینت‌های هر دو اکوسیستم بدون نیاز، HTTP/2 می‌شوند، با بازگشت خودکار به به تغییر متصل می‌شوند.
- در یک کدبیس واحد پشتیبانی می‌کند ROCm و Metal و CUDA استنتاج محلی که از همان بیلد روی سخت‌افزارهای انویدیا، اپل و ای‌ام‌دی با شتاب اجرا می‌شود.

بزرگ‌ترین چالش‌های فنی و راه‌حل‌های ما

- بیشتر سیستم‌ها مرز سخت‌گیرانه‌ای. مقیاس‌پذیری از یک میزبان به چند میزبان بدون بازنویسی بین «توسعه محلی» و «تولید توزیع‌شده» قائل می‌شوند و عبور از این مرز به معنای بازطراحی معماری است. ما این مرز را با سیستمی حالت‌محور در یک باینری واحد حذف کردیم: همان لایه‌ها از طریق فراخوانی‌های مستقیم درون‌فرایندی ارتباط برقرار می‌کنند و به طور شفاف full در حالت سوئیچ می‌کنند، به طوری که مقیاس‌پذیری gRPC/SSE/Kafka در حالت‌های توزیع‌شده به تنها یک تغییر پیکربندی است نه یک انتقال.
- استنتاج لایه رایگان تازمانی که با ارائه‌دهندگان ابری رایگان غیرقابل اعتماد و محدود به نرخ خطای ۴۲۹ مواجه نشود یا در میانه درخواست ناپدید نشود، سریع است. ما آن را قابل اعتماد ردیابی پیشگیرانه، LLMsVerifier ساختیم با کشف خودکار مدل‌های موجود، امتیازدهی آن‌ها با مهرهای محدودیت نرخ برای دور زدن ارائه‌دهندگانی که در آستانه محدودسازی هستند، و شکست محلی—به طوری که ناپایداری این llama.cpp خودکار به پایین زنجیره رتبه‌بندی‌شده تا مجموعه هرگز به کلاینت نمی‌رسد.
- بازنویسی کلاینت‌ها برای پذیرش یک بک‌اند استنتاجی جدید. سازگاری کلاینت در دو اکوسیستم تا جزئیات Anthropic و OpenAI مربوط به API غیرممکن است. ما هر دو شکل های هر دو اردوگاه SDK متمایز آن‌ها—را پیاده‌سازی کردیم، به طوری که SSE فرمت‌های استریم اشاره می‌کنند و به سادگی کار می‌کنند HelixLLM به

محتوا

پشته فناوری

- انتخاب شده زیرا یک باینری واحد با اولویت همزمانی، چیزی است که کل — **Go + Gin** سیستم حالت‌ها را ممکن می‌سازد: یک بیلد که می‌تواند هم به عنوان سرور لپ‌تاپ و هم نقش دروازه‌ها در خود جای می‌دهد HTTP کلاستر عمل کند. این باینری کل سیستم و لایه انتخاب شده برای — **HTTP/2** با بازگشت به ۱,۳۰ **HTTP/3 (QUIC) + TLS** انتقال مدرن، کم‌تأخیر و مقاوم در برابر قطع اتصال، که به عنوان سطح سرور با مذاکره خودکار ارائه HTTP/2 استفاده کنند، به صورت خودکار به QUIC می‌شود تا کلاینت‌هایی که نمی‌توانند از بازگردند.
- انتخاب شده برای استنتاج محلی — **llama.cpp (CUDA/Metal/ROCm)** قابل حمل که روی بک‌اند‌های انویدیا، اپل و ای‌ام‌دی از یک کدبیس واحد شتاب می‌گیرد؛ همچنین به عنوان تأمین‌کننده تضمینی آخرین راهکار عمل می‌کند تا زنجیره بازگشت هرگز به بن‌بست نرسد.
- انتخاب شده تا پرسش «کدام تأمین‌کننده در حال حاضر خوب است» را — **LLMsVerifier** به عدد تبدیل کند؛ این ابزار زنجیره بازگشت ابری را هر پنج دقیقه امتیازدهی و رتبه‌بندی می‌کند تا مسیریابی بر اساس کیفیت زنده انجام شود، نه فرضیات قدیمی.

- **Chutes. OpenRouter. HuggingFace. Nvidia. Cerebras. SambaNova. Together** — انتخاب شده برای بهره‌برداری از ظرفیت لایه رایگان در چندین منبع بالادستی؛ به صورت خودکار کشف و در یک زنجیره بازگشت واحد رتبه‌بندی می‌شوند تا هیچ تأمین‌کننده‌ای نقطه شکست نباشد.
- **gRPC + SSE + Kafka** — انتخاب شده به عنوان پروتکل‌های انتقال بین‌حالتی برای برای جریان‌سازی و SSE، برای تماس‌های سرویس به سرویس gRPC: استقرارهای توزیع شده برای جریان رویدادهای غیرهمزمان بین نقش‌ها Kafka.
- **RAG** انتخاب شده برای تقویت خط لوله دانش — **embeddings / پایگاه داده برداری**. ابتدا تا انتها: دریافت، قطعه‌بندی، تعبیه و جستجو در اسناد برای پایه‌گذاری پاسخ‌های مدل.
- **Prometheus + OpenTelemetry** — انتخاب شده برای معیارها و ردیابی — توزیع شده که یک درخواست را در هر حالتی که مستقر شده باشد دنبال می‌کند.
- انتخاب شده برای استفاده مجدد از زیرساخت‌های **vasic-digital Go** زیرماترول‌های تولیدی سخت‌شده به جای بازسازی آن‌ها، تا پایه سیستم با پشته گسترده‌تر هماهنگ بماند.

وضعیت و یادداشت‌های شفافیت

- سیستم استنتاج توزیع شده کاربردی و در حال توسعه فعال **وضعیت: بتا**.
- (تهی **licenseInfo**) مخزن در متادیتای خود هیچ مجوزی اعلام نکرده است. **مجوز: نامشخص**. این وضعیت تأیید نشده است و باید پیش از اعلام مجوز حل شود —
- ارجاع می‌دهد؛ **github.com/HelixDevelopment/llm** مخزن مرجع در حال حاضر به به آن تغییر مسیر می‌دهد. آمار آستانه پوشش و تعداد زیرماترول‌ها در فایل **HelixLLM** مسیر **README** خوداظهاری شده است.

اصلی-Helix: **اولویت سطح**.