

CV

Miloš Vasić

AI 엔지니어 — LLM 인프라, 자율 에이전트, 그리고 이를 신뢰할 수 있게 만드는 거버넌스

- 이메일: milos85vasic@gmail.com
- 웹: <https://milosvasic.ru> · <https://vasic.digital>
- GitHub: vasic-digital · HelixDevelopment · Server-Factory

요약

AI/소프트웨어 엔지니어로, 멀티 프로바이더 LLM 인프라와 자율 에이전트부터 이를 검증하고 신뢰성을 확보하는 QA 및 거버넌스 레이어까지 엔드 투 엔드로 구축합니다. 저는 데모를 배포하지 않습니다. 플랫폼을 배포합니다. 15년 이상의 전문 엔지니어링 경력(2009년부터)을 바탕으로 모바일 SDK, 실시간 하드웨어 통합, 분산 백엔드 등 다양한 분야를 아우르며 한 가지 목표에 집중하고 있습니다. 바로 대규모 자율 AI 개발의 신뢰성을 확보하는 것입니다.

저는 모놀리식 시스템이 아닌 '함대'를 설계합니다. 수십 개의 작은 독립 모듈로 구성된 대규모 제품 애플리케이션으로, 각 모듈은 공유된 엔지니어링 Constitution을 계승하며, 허위 없이 증거 기반으로 검증되는 엄격한 QA 프로세스를 거칩니다. 주요 언어는 Go이며, Kotlin/KMP, TypeScript/React, Python, Swift, Shell 등을 사용합니다. 기계적으로 강제되는 핵심 원칙은 단 하나입니다. '실제 사용자가 사용할 수 있고, 이를 증명할 증거가 확보되었을 때만 기능이 완료되었다고 간주한다.'

제 강점: 연구 아이디어로 시작된 AI 역량을 거버넌스가 적용되고, 자가 검증되며, 프로덕션 수준의 시스템으로 발전시키는 능력입니다. 각 모델이 실제로 작동한다는 증거를 확보하기 전까지는 신뢰하지 않는 LLM 라우팅, 추측 대신 토론과 합의를 통해 결론을 도출하는 에이전트, 맥락을 잃지 않는 메모리와 RAG 레이어, 그리고 '테스트가 통과했다'는 말이 결코 '기능이 작동하지 않는다'는 의미가 되지 않도록 설계된 전체 생태계입니다.

핵심 역량

- **AI / LLM 시스템:** 멀티 프로바이더 LLM 추상화(40개 이상 프로바이더), MCP 도구 통합, RAG, vector 데이터베이스 및 embeddings, 에이전트 오케스트레이션(헤드리스 CLI 에이전트, 그래프 워크플로우, 다중 라운드 토론/합의), 플래닝(HiPlan/MCTS/Tree-of-Thoughts), LLMOps, 벤치마킹(SWE-bench/HumanEval/MMLU), LLM 검증, 방어적 LLM 가드레일, 컴퓨터 비전 + LLM 비전.
- **백엔드 엔지니어링:** Go(Gin), gRPC + Protobuf, HTTP/3(QUIC), WebSocket, 분산 시스템(TLA+ 형식 명세 포함), 고처리량 REST 서비스 및 동시성 워커.
- **데이터:** PostgreSQL, SQLite, SQLCipher(저장 데이터 암호화), Redis, Neo4j, ClickHouse, 객체 스토리지(MinIO/S3/GCS/Azure).
- **프론트엔드 / 크로스 플랫폼:** TypeScript/React(Tailwind, Redux Toolkit, i18next), Angular, Electron, React Native, Kotlin Multiplatform, Android/Android TV(Kotlin), iOS(Swift), Tauri/Rust.
- **인프라 / DevOps:** Docker & Compose, Kubernetes + Helm, Prometheus + Grafana, OpenTelemetry, QEMU/Libvirt/Parallels; CI/CD via GitHub Actions, Gradle, Make.
- **QA / 품질 엔지니어링:** 허위 없는 증거 기반 QA(HelixQA), 변이 게이트가 적용된 챌린지 하네스, go test -race, 시각적 회귀 테스트, ADB 디바이스 테스트, SonarQube, 보안 스캐닝(semgrep/gosec/trivy/snyk/gitleaks/nancy).
- **엔지니어링 거버넌스:** Constitution-as-submodule; 상속 및 전파 게이트; 140개 이상의 레포지토리에서 적용되는 문서화/커버리지 규율.

주요 프로젝트

거버넌스 및 품질 보증

- **HelixConstitution** — Git 서브모듈로 배포되어 140개 이상의 저장소에 상속되는 범용 엔지니어링 규칙집: 엔지니어링 법규가 코드처럼 배포되고 버전 고정됩니다. 하나의 서브모듈 업데이트로 전체 시스템의 규칙이 한 번에 업그레이드되며, 전파 게이트는 모든 종속 저장소를 대상으로 필수 조항을 문자 그대로 검색합니다. 각 게이트는 게이트 자체가 허점이 아님을 증명하는 변형 메타 테스트와 짝을 이룹니다. 이는 “사람들이 따르기 원하는 모범 사례”를 상속 가능하고, 감사 가능하며, 기계적으로 강제되는 반블러핑 법규로 전환합니다.
- **HelixQA** — 한 가지 타협 없는 원칙에 기반한 반블러핑 품질 보증 오케스트레이션(Go): 기준은 “테스트 통과”가 아니라 “사용자가 기능을 실제로 사용할 수 있느냐”입니다. 서면 YAML 테스트 बैं크와 완전 자동화된 LLM 및 비전 기반 QA 세션을 실행하여 실제 앱을 열고, 문서화된 모든 기능을 검증하며, Android/Android TV/Web/데스크톱 전반에 걸쳐 문서화되지 않은 버그를 탐지합니다. 또한 런타임 증거(스크린샷, 로그캣, 영상, 스택 트레이스)와 AI 수정 준비 완료 티켓이 확보되지 않으면 PASS 점수를 부여하지 않습니다.

AI 개발 및 LLM 인프라

- **HelixAgent** — 단일 모델을 신뢰하지 않는 프로덕션급 LLM 양상블 서비스(Go/Gin): 여러 제공업체에 프롬프트를 분산하고, 구조화된 다중 라운드 토론(제안 → 비판 → 검토 → 종합)을 진행하며, 실시간 검증 점수를 기반으로 라우팅하고 우아한 풀백을 제공합니다. 모든 기능은고가용성 데이터 레이어, 관측 가능성, 안전장치를 갖춘 OpenAI 호환 API 뒤에서 운영됩니다. *Go, Gin, PostgreSQL, Redis, Prometheus/Grafana/OpenTelemetry, MCP, Neo4j/ClickHouse/Kafka.*
- **HelixCode** — SSH로 관리되는 워커 클러스터에서 작업을 지능적이고 의존성 인식형 태스크로 분할하는 분산 AI 개발 플랫폼: 작업이 중단되더라도 체크포인트와 롤백을 통해 데이터 손실이 발생하지 않습니다. 하드웨어 인식 모델 선택과 REST/CLI/TUI/MCP 기반의 전체 계획/빌드/테스트/리팩터링 라이프사이클을 지원합니다. *Go, Gin, PostgreSQL, Redis, SSH, MCP, llama.cpp/Ollama.*
- **HelixLLM** — 하나의 바이너리, 여섯 가지 배포 모드: OpenAI 및 Anthropic 호환 추론을 지원하는 HTTP/3 기반으로 노트북부터 다중 호스트 클러스터까지 확장 가능하며, 로컬 llama.cpp 추론(CUDA/Metal/ROCm)과 자동 검색 및 검증 점수 기반 클라우드 풀백 체인을 제공합니다. 항상 로컬 모델로 안전하게 풀백됩니다. *Go, HTTP/3 QUIC, gRPC/SSE/Kafka, llama.cpp.*
- **LLMProvider / LLMOrchestrator / LLMsVerifier** — LLM 인프라의 중추: 43개 제공업체를 아우르는 단일 인터페이스에 서킷 브레이커, 상태 모니터링, 지터 백오프 재시도, 정직한(하드코딩된 풀백 없는) 모델 검색 기능을 탑재했습니다. 하이브리드 파이프+파일 프로토콜을 통해 헤드리스 CLI 에이전트(OpenCode, Claude Code, Gemini, Junie, Qwen Code)를 생성하고 제어하는 스레드 안전 제어 플레인입니다. 또한 “내 코드를 보시나요?”라는 필수 게이트를 통과한 모델만 사용 가능 또는 내보내기 가능한 것으로 표시하는 검증 진실 공급원입니다.
- **HelixMemory / HelixSpecifier** — 네 가지 최상급 백엔드(Mem0, Cognee, Letta, Graphiti)를 단일 인터페이스로 통합한 통합 인지 메모리 엔진으로, 병렬 검색과 교차 소스 재랭킹을 지원합니다. 또한 작업 규모에 맞게 자체 의례를 조정하고 다중 에이전트 토론으로 사양을 뒷받침하는 사양 주도 개발 퓨전 엔진입니다.
- **HelixTrack** — 자유 세계의 JIRA + Confluence 대체 솔루션(HelixTrack 라인의 플래그십): HTTP/3 기반의 통합 액션 라우팅 API를 갖춘 Go 마이크로서비스로, 저장 시 암호화(SQLCipher)와 네이티브 Web/데스크톱/Android/iOS 클라이언트를 지원합니다.

콘텐츠

제품급 도구 (vasic-digital utils)

- **Catalogizer** — 멀티 프로토콜, 암호화, 자가 호스팅 가능한 미디어 컬렉션 관리 시스템 (Go/Gin + React). 불안정한 네트워크 스토리지에도 견고하며, 21개의 재사용 가능한 서브모듈로 구축됨.
- **Courses-Creator** — 마크다운-투-비디오 AI 강의 파이프라인(TTS 포함) 및 데스크톱/모바일/웹 플레이어 지원.
- **VisionEngine** — 컴퓨터 비전 + 멀티 프로바이더 LLM 비전 UI 인식 및 내비게이션 그래프 통합.

- **DocProcessor · Docs Chain · Herald · task_bridge · Vasic Digital** 재사용 모듈 스위트 — QA 기능 매핑, 콘텐츠 해시 기반 문서/DB 동기화, 자연어 알림, 작업/보드 동기화, digital.vasic.* 표준 라이브러리 세트.

인프라 자동화 (Server Factory)

- **Mail Server Factory** — 선언형 JSON 기반으로 12개 연결 유형 및 25개 Linux 배포판에 걸쳐 완전 프로비저닝된 도커화 메일 서버 구축. 439개 테스트 통과 및 SonarQube 게이트 클린 상태 보고.
- **Server Factory** 코어 프레임워크, **Qemu-Utills, Parallels-Utills** — 공유 프로비저닝 엔진 및 VM 이미지 툴링.

언어 및 도구 (간략 목록)

Go · Kotlin · Kotlin Multiplatform · TypeScript · JavaScript · Python · Swift · Java · Rust · Shell · PL/pgSQL · TLA+ · Gin · gRPC · HTTP/3 · React · Angular · Electron · React Native · PostgreSQL · SQLite · SQLCipher · Redis · Neo4j · ClickHouse · Docker · Kubernetes · Prometheus · Grafana · OpenTelemetry · QEMU · GitHub Actions · Gradle · Make

경력

2009년부터 소프트웨어 엔지니어로 전 개발 라이프사이클(기획, 개발, 팀 리딩, 배포)에 걸쳐 활동. 아래 전체 경력은 후보자의 검증된 기록 (milosvasic.ru)에서 발췌.

정규직 경력

- **SDK 개발자 — Harness** (harness.io), 베오그라드, 세르비아 · 2020년 3월 - 2024년 12월. 회사의 Feature Flag 부문 SDK 제품군 리드 개발자로, 주요 모바일 플랫폼 및 그 외 플랫폼을 담당. 고객 및 파트너로는 AWS, Google 및 다양한 은행 포함. 기술: *Android, iOS, Flutter, React Native, TypeScript, JavaScript, Java, Kotlin, Swift, Go, Ruby*.
- **소프트웨어 엔지니어 — Leica Geosystems** (leica-geosystems.com), 헤어브루크, 스위스 · 2016년 2월 - 2020년 2월. Leica Geosystems의 최첨단 3D 스캐너용 iOS 및 Android 엔지니어링을 주로 담당. 하드웨어와의 실시간 통신, 데이터 처리 및 동기화. 파트너: Autodesk. 기술: *Android, iOS, Java, Kotlin, Swift, C++*.
- **SDK 개발자 — Bosch** (bosch.rs), 베오그라드, 세르비아 · 2010년 1월 - 2016년 1월. 커넥티드 비히클 SDK 프로젝트의 리드 SDK 개발자로, OBD2 버스와의 실시간 Bluetooth 통신, 고성능 데이터 처리 및 영속성 담당. 기술: *Android, Java, Kotlin*.

내용

기타 활동

- **TN-TECH** (tn-tech.co.rs), 세르비아 노비사드 · 파트타임, 2017년 3월부터. 글로벡스 데이터(캐나다 및 스위스) — 세쿠르 (SekurMessenger), 세쿠르메일(SekurMail), 세쿠르스 스위트 (SekurSuite) — 및 BusRide 플랫폼 개발 참여. 기술: 안드로이드, 자바, *Kotlin*, *C++*, *Qt*.
- **Increment Loop** (incrementloop.com), 세르비아 베오그라드 · 파트타임, 2023년 9월부터. 유노(Yuno) 애플리케이션 개발. 기술: 안드로이드, *Kotlin*.
- 오픈소스 / 개인 프로젝트 — HelixTrack, Server Factory (Mail Server Factory, Parallels-Utils, Qemu-Utils) 및 Vasic Digital(Android-Toolkit, Network-Binder). 자세한 내용은 위의 '선정 프로젝트' 항목 참조.

출판물

- 『**Fundamental Kotlin**』 — 개인 출판, 최신 개정판 2022년 9월 출간(『Fundamental Kotlin』 3판). 또한 Packt 출판사(영국)를 통해 집필.

학력

- 현대 정보기술학 석사(**M.Sc**) — 세르비아 베오그라드 Singidunum 대학교 · 2014년.
- 정보컴퓨팅학 학사(**B.Sc**) — 세르비아 베오그라드 Singidunum 대학교 · 2008년.