

CV

Miloš Vasić

AI инжењер — LLM инфраструктура, аутономни агенти и управљање које их чини поузданим.

- Емаил: milos85vasic@gmail.com
 - Web: <https://milosvasic.ru> · <https://vasic.digital>
 - GitHub: [vasic-digital](#) · [HelixDevelopment](#) · [Server-Factory](#)
-

Сажетак

AI/софтверски инжењер који гради системе за развој AI од почетка до краја — од LLM инфраструктуре са више провајдера и аутономних агената до слојева за контролу квалитета и управљање који их држе под надзором. Не испоручујем демо верзије; испоручујем платформе. Више од 15 година професионалног инжењеринга (од 2009. године) у области мобилних SDK-ова, интеграције хардвера у реалном времену и дистрибуираних бацкенд система сада се усредсређује на један циљ: учинити аутономни развој AI поузданим на великој скали.

Пројектујем флоте, а не монолитне системе — велике апликације које се ослањају на десетине малих, одвојених и независно тестираних модула, од којих сваки наслеђује заједнички инжењерски Constitution и проверава се кроз дисциплину контроле квалитета засновану на доказима, без варања. Примарни језик је Go, уз Kotlin/KMP, TypeScript/React, Python, Swift и Shell. Вођено начело, које се примењује механички, а не само декларативно: функционалност је готова тек када је стварни корисник може користити и када постоје прикупљени докази који то потврђују.

Шта доносим на сто: способност да се AI могућност преведе из истраживачке идеје у управљани, самоверификујући систем прилагођен продукцији — LLM рутирање које доказује да сваки модел заиста функционише пре него што му се повери, агенти који расправљају и постижу консензус уместо да

нагађају, слојеви за меморију и RAG који не губе контекст, и читав екосистем повезан тако да „тестови су зелени” никада не значи „функционалност је покварена”.

Кључне компетенције

- **AI / LLM системи:** апстракција LLM инфраструктуре са више провајдера (40+ провајдера), интеграција MCP алата, RAG, векторске базе података и ембединзи, оркестрација агената (безглави CLI агенти, графовски токови послова, вишеструке рунде дебате/консензуса), планирање (HiPlan/MCTS/Tree-of-Thoughts), LLMOps, бенцхмаркинг (SWE-bench/HumanEval/MMLU), верификација LLM, одбрамбени LLM сигурносни механизми, рачунарски вид + LLM-вид.
- **Бацкенд инжењеринг:** Go (Gin), gRPC + Protobuf, HTTP/3 (QUIC), WebSockets, дистрибуирани системи (укључујући формалне TLA+ спецификације), високопропусни REST сервиси и конкурентни радници.
- **Подаци:** PostgreSQL, SQLite, SQLCipher (шифровање у мировању), Redis, Neo4j, ClickHouse, објекти складиштења (MinIO/S3/GCS/Azure).
- **Фронтенд / просс-платформ:** TypeScript/React (Tailwind, Redux Тоолкит, i18next), Angular, Electron, React Native, Kotlin Multiplatform, Android/Android TV (Kotlin), iOS (Swift), Tauri/Rust.
- **Инфра / DevOps:** Docker и Цомпосе, Kubernetes + Helm, Prometheus + Grafana, OpenTelemetry, QEMU/Libvirt/Parallels; CI/CD путем GitHub Actions, Gradle, Make.
- **Контрола квалитета / инжењеринг квалитета:** контрола квалитета заснована на доказима без варања (HelixQA), оквири за изазове са мутационим капијама, go test -race, визуелно-регресионо тестирање, тестирање уређаја преко ADB-a, SonarQube, скенирање сигурности (semgrep/gosec/trivy/snyk/gitleaks/nancy).
- **Управљање инжењерингом:** Constitution као подмодул; капије за наслеђивање и пропагацију; дисциплина документације и покривености кроз флоту од 140+ репозиторијума.

Изабрани пројекти

Управљање и контрола квалитета

- **HelixConstitution** — универзални инжењерски приручник дистрибуиран као Гит подмодул и наслеђен у преко 140 репозиторијума: инжењерски закон испоручује се и верзионира тачно као код. Једно ажурирање подмодула унапређује правила за цео систем, а пропагациони филтери

дословно претражују сваки репозиторијум који га користи у потрази за обавезном клаузулом — сваки филтер упарен је са мутационим метатестом који доказује да сам филтер није лажан. Претвара „најбоље праксе које људи желе да прате” у наслеђено, проверљиво, механички спроводиво право без преваре.

- **HelixQA** — оркестрација контроле квалитета без преваре (Go) заснована на једном непопустљивом правилу: мера није „тестови пролазе”, већ „корисници могу да користе функцију”. Покреће писане YAML тест-банке и потпуно аутономне LLM-и-визуелне сесије контроле квалитета које отварају стварну апликацију, проверавају сваку документовану функцију, трагају за недокументованим грешкама на Андроиду/Android TV/Webu/десктопу и одбијају да оцене пролазак без снимљених доказа у реалном времену — снимака екрана, логцат-а, видео-записа, стек-трејсова — плус тикета спремних за AI исправке.

Развој AI и LLM инфраструктура

- **HelixAgent** — продукцијски ансамбл LLM услуга (Go/Gin) која одбија да верује једном моделу: шаље упит на више провајдера, води структурисану вишестепену дебату (Предлог → Критика → Преглед → Синтеза) и усмерава према резултатима провере уживо са поступним повлачењем — све иза OpenAI-компатибилног API интерфејса са HA слојем података, опсервабилношћу и заштитним механизмима. *Go, Gin, PostgreSQL, Redis, Prometheus/Grafana/OpenTelemetry, MCP, Neo4j/ClickHouse/Kafka*.
- **HelixCode** — дистрибуирана платформа за развој AI која дели посао на интелигентне задатке свесне зависности, распоређене на радничкој мрежи под управом SSH, а затим чува контролне тачке и враћа се уназад тако да ништа никада не буде изгубљено ако се задатак прекине; избор модела свесних хардвера и цео циклус планирања/израде/тестирања/рефакторисања иза REST/CLI/TUI/MCP. *Go, Gin, PostgreSQL, Redis, SSH, MCP, лама.цпн/Ollama*.
- **HelixLLM** — један бинарни фајл, шест режима имплементације: OpenAI- и Anthropic-компатибилно закључивање преко HTTP/3 које скалирамо од лаптопа до вишенаменског кластера, са локалним закључивањем преко лама.цпп (CUDA/Метал/ROCm) и аутоматски откривајућим, верификационо оцењеним ланцем резервног решења у облаку који увек деградира на загарантовани локални модел. *Go, HTTP/3 QUIC, gRPC/SSE/Kafka, лама.цпп*.
- **LLMProvider / LLMOrchestrator / LLMsVerifier** — кичма LLM инфраструктуре: један интерфејс преко 43 провајдера са прекидачима струјног кола, мониторингом здравља,

поновним покушајима са експоненцијалним одлагањем и поштеним (без унапред задатих резервних решења) откривањем модела; тхреад-сафе контролна равна која покреће и управља хеадлесс CLI агента (OpenCode, Claude Цоде, Gemini, Junie, Qwen Цоде) преко хибридног протокола цеви и фајлова; и извор истине за верификацију чији обавезни филтер „Видиш ли мој код?” значи да се као употребљиви или за извоз означавају само модели за које је доказано да стварно раде.

- **HelixMemory / HelixSpecifier** — обједињени когнитивно-меморијски погон који спаја четири врхунска бацкенда (Mem0, Cogneе, Letta, Graphiti) иза једног интерфејса са паралелним претраживањем и поновним рангирањем из више извора; и погон за развој заснован на спецификацијама који прилагођава сопствену процедуру обиму посла и подржава спецификације вишеструком агентском дебатном.
- **HelixTrack** — алтернатива JIRA + Confluence-у отвореног света (заставни пројекат Helix-Track линије): Go микросервиси са јединственим API интерфејсом усмереним акцијама преко HTTP/3, SQLCipher енкрипцијом у мировању и клијентима за Web/Десктоп/Android/iOS.

Алати професионалног нивоа (vasic-digital утилс)

- **Catalogizer** — вишенаменски, енкриптован, самостално хостован систем за управљање медијским колекцијама (Go/ Gin + React), отпоран на нестабилне мрежне складишне системе, изграђен на 21 поново употребљивом потмодулу.
- **Courses-Creator** — пипелине за конверзију markdown-а у видео AI са TTS и плејерима за десктоп, мобилне и веб платформе.
- **VisionEngine** — рачунарски вид + вишенаменски LLM визуелни интерфејс са навигационим графовима.
- **DocProcessor · Docs Chain · Herald · task_bridge · Vasic Digital** Пакет поново употребљивих модула — мапирање функција за контролу квалитета, синхорнизација докумената/база података са хешираним садржајем, обавештења на природном језику, синхорнизација задатака/табли и флота стандардне библиотеке digital.vasic.*.

Аутоматизација инфраструктуре (Server Factory)

- **Mail Server Factory** — декларативни JSON → потпуно конфигурисани, докеризовани mail сервери за 12 врста конекција и 25 Linux дистрибуција; извештава о 439 успешно положених тестова и чистој SonarQube капији.

- **Server Factory Основни оквир, Qemu-Utills, Parallels-Utills** — заједнички провизионинг погон и алати за креирање VM слика.

Језици и алати (кратак списак)

Go · Kotlin · Kotlin Multiplatform · TypeScript · JavaScript · Python · Swift · Java · Rust · Shell · PL/pgSQL · TLA+ · Gin · gRPC · HTTP/3 · React · Angular · Electron · React Native · PostgreSQL · SQLite · SQLCipher · Redis · Neo4j · ClickHouse · Docker · Kubernetes · Prometheus · Grafana · OpenTelemetry · QEMU · GitHub Actions · Gradle · Make

Искуство

Софтверски инжењер од 2009. године, са искуством у целом развојном циклусу — планирање, развој, вођење тима и имплементација. Потпуна историја у наставку преузета је из кандидатовог верификованог записа (milosvasic.ru).

Стални послови

- **SDK Девелопер — Harness** (харнесс.ио), Београд, Србија · 03/2020 – 12/2024. Главни програмер на породици SDK-ова за компанијин одсек Феатуре Флаг, са фокусом на све главне мобилне платформе и шире. Клијенти и партнери укључивали су AWS, Google и разне банке. *Технологије: Android, iOS, Flutter, React Native, TypeScript, JavaScript, Java, Kotlin, Swift, Go, Ruby.*
- **Софтверски инжењер — Leica Geosystems** (леица-geosystems.цом), Herbrugg, Швајцарска · 02/2016 – 02/2020. Примарно iOS и Android програмирање за врхунске 3Д скенере компаније Leica Geosystems — комуникација у реалном времену са хардвером, обрада података и синхорнизација. Партнер: Autodesk. *Технологије: Android, iOS, Java, Kotlin, Swift, C++.*
- **SDK Девелопер — Bosch** (босцх.рс), Београд, Србија · 01/2010 – 01/2016. Главни SDK програмер на пројекту Цоннецтед Вехицлес SDK — комуникација у реалном времену са Bluetooth сабирницом OBD2, обрада података високих перформанси и њихово чување. *Технологије: Android, Java, Kotlin.*

Остале професионалне активности

- **TN-TECH** (тн-тецх.цо.рс), Нови Сад, Србија · хонорарно, од 03/2017. Рад за Globex Дата (Канада и Швајцарска) — Sekur

(SekurMessenger), SekurMail, SekurSuite — и платформу BusRide. *Технологије: Android, Java, Kotlin, C++, Qt.*

- **Increment Loop** (инкрементлооп.цом), Београд, Србија · хонорарно, од 09/2023. Апликација Yuno. *Технологије: Android, Kotlin.*
- **Отворени код / сопствене организације** — HelixTrack, Server Factory (Mail Server Factory, Parallels-Utils, Qemu-Utils) и Vasic Digital (Android-Тоолкит, Network-Биндер), детаљније описано у одељку Изабрани пројекти изнад.

Публикације

- **Фундаментални Kotlin** — самостално објављени аутор; последње ревидирано издање септембар 2022. (Фундаментални Kotlin, 3. издање). Такође аутор за Packt Публисхинг (Велика Британија).

Образовање

- **М.Сц, Савремене информационе технологије** — Универзитет Singidunum, Београд, Србија · 2014.
- **Б.Сц, Информатика и рачунарство** — Универзитет Singidunum, Београд, Србија · 2008.