

HelixAgent

HelixAgent

Не бирај један модел — пусти их да дебатују и испоручи одговор на којем се сложе.

Сажетак

HelixAgent је производно спремна услуга ансамбла LLM покретана AI технологијом у Go окружењу, која интелигентно комбинује одговоре из више језичких модела — укључујући вишестепени систем дебате AI и динамички избор провајдера заснован на верификацији — како би произвела најтачнији и најпоузданији резултат.

Кратак опис

HelixAgent је услуга ансамбла LLM заснована на Go платформи која обједињује више провајдера у један прецизан одговор. Покреће вишестепене дебате AI, динамички бодује провајдере путем LLMsVerifier, усмерава саобраћај стратегијама пондерисаним поверењем и испоручује производне функционалности: кеширање, надзор, сигурносне заштитне мере и API-је у стилу OpenAI.

Детаљан опис

HelixAgent је производно спремна услуга ансамбла LLM покретана AI технологијом (МИТ лиценца) која третира одговор једног модела као хипотезу, а не као коначну пресуду. Уместо да се исход ослања на једног провајдера који може бити погрешан, пристрасан или привремено недоступан, она комбинује одговоре из више језичких модела како би се дошло до најтачнијег и најпоузданијег резултата — а када је питање довољно сложено да то оправда, покреће моделе кроз структурирану, вишестепену дебату. Списак је широк: у

PEADME фајлу документовани су бројни провајдери LLM под `internal/llm/providers/`, укључујући Claude, DeepSeek, Gemini, Mistral, Qwen и xAI/Grok.

Кључно је да избор провајдера није статичка листа преференци — он се заслужује у реалном времену. Резултати верификације уживо из интегрисаног LLMsVerifier система покрећу усмеравање и елегантно пребацивање на најбоље перформирајућег провајдера, уз категоризовано извештавање о грешкама када неки од њих почне да слабије ради. AI Дебатни оркестратор претвара неслагање у сигнал: подржава више топологија (мрежа, звезда, ланац) и дисциплинован протокол фаза — Предлог → Критика → Преглед → Синтеза — уз учење из претходних дебата како би систем временом боље усаглашавао моделе. Стратегије усмеравања обухватају избор пондерисан поверењем, консензус већином гласова и детекцију семантичке намере, све уз стримовање одговора у реалном времену тако да резултати стижу токен по токен, уместо да се чека да се цео ансамбл усагласи.

Услуга је пројектована да преживи у продукцији, а не само да добро изгледа на демонстрацијама: PostgreSQL и Redis чине слој података високе доступности, Prometheus/Grafana/OpenTelemetry обезбеђују метрике, контролне табле и праћење, а JWT аутентификација, ограничење броја захтева, мотор заштитних мера и детекција PII обавијају ансамбл контролама које су неопходне за стварну примену. Организована је у око двадесет издвојених модула (EventBus, Observability, Аутх, Стораге, VectorDB, Ембеддингс, RAG, Memory, MCP и други), од којих је сваки засебна целина, а испоручује и оквир за оптимизацију LLM (семантичко кеширање, структурирани излаз, побољшано стримовање) са интеграцијама за SGLang, LlamaIndex, LangChain, Гуиданце и LMQL. Пошто су ендпоинти за комплетирање и ансамбл компатибилни са OpenAI стандардом, постојећи клијент може да се повеже на HelixAgent и добије ансамблирано резонување без потребе за преправкама.

Зашто смо га изградили

Сваки појединачни LLM може бити погрешан, пристрасан или недоступан. HelixAgent је створен како би апликације могле да се консултују са више модела истовремено, да одмере њихове одговоре према мереној поузданости и да се елегантно повуку – претварајући крхку зависност од једног провајдера у отпоран, самопроцењујући ансамбл.

Зашто је револуционаран

Операционализује консензус више модела – пребацује „питај неколико модела и усклади одговоре“ из импровизованих скрипти у производну услугу. Уместо да се ослањају на једног провајдера и надају се најбољем, тимови добијају рутирање вођено резултатима верификације уживо, структурирани протокол дебате за питања где један покушај није довољан, и отпорност на нивоу продукције (НА слој података, потпуну опсервабилност и заштитне механизме) – све иза OpenAI-компатибилног API. Кључна предност је усвајање без прекида: једна крхка зависност од провајдера постаје отпоран, самопроцењујући ансамбл, а постојећи клијенти прелазе на њега променом крајње тачке уместо кода.

Шта је иновативно

- Структурирана вишестепена AI дебата која третира неслагање модела као ресурс: избор мрежних/звездастих/ланчаних топологија, дисциплинован протокол Предлог→Критика→Преглед→Синтеза, и учење на основу претходних дебата које се акумулира током времена.
- Динамички избор провајдера заснован на резултатима LLMsVerifier оцењивања уживо уместо на статичкој листи преференци – ансамбл усмерава упите ка ономе ко тренутно најбоље функционише и елегантно се повлачи када неко заказује.
- Изворни Go оквир оптимизован за LLM (семантички кеш, структурирани излаз, побољшан стриминг) који стоји сам за себе, са опционим спољним оптимизаторима (SGLang, LlamaIndex, LangChain, Гуиданце, LMQL) који се могу додати по потреби, а не обавезно.
- Модуларна архитектура састављена од двадесетак издвојених модула која одржава раздвојеност одговорности и отвара врата за функције великих података попут дистрибуиране меморије и стриминга графова знања.

Највећи технички изазови и како смо их решили

- **Избор међу многим неједнаким провајдерима.** Провајдери се разликују по квалитету и временом мењају перформансе, па је свако фиксно рангирање већ сутра застарело. Решили смо то континуираним мерењем: LLMsVerifier оцене напајају рутирање засновано на пондерисаном поверењу и већинском гласању, са елегантним повлачењем како би се заобишао провајдер који се погоршава уместо да му се верује.

- **Добијање поузданог одговора на заиста тешка питања.** Један модел, питан једном, нема механизам да ухвати сопствену грешку. Дебатни оркестратор то омогућава – вишеструке топологије, фазна дебата (Предлог → Критика → Преглед → Синтеза) која приморава моделе да се међусобно преиспитују и усавршавају пре него што се коначан одговор синтетизује.
- **Покретање ансамбла у продукцији, а не само у бележници.** Распростирање на више провајдера умножава површину за грешке. Ограничили смо је помоћу HA слоја података PostgreSQL+Redis, опсервабилности Prometheus/Grafana/OpenTelemetry за случајеве када провајдер или рута не функционишу како треба, и сигурносног периметра који укључује JWT аутентификацију, ограничење броја захтева, мотор заштитних механизма и детекцију PII.

Технолошки стек

- **Go** — изабран зато што је распршивање једног захтева на више провајдера истовремено управо оно за шта су горутине намењене, а испорука у виду једног бинарног фајла чува једноставност сервиса од ~20 модула; чини темељ целог сервиса и сваког интерног модула.
- **Gin (Web API)** — изабран због брзог, нискооптерећеног ХТТП интерфејса; служи OpenAI-компатибилним /v1 ендпоинтима за допуњавање, ћаскање, стримовање и ансамбл, који омогућавају постојећим клијентима да усвоје ансамбл без промена.
- **PostgreSQL** — изабран као трајна меморија за сесије, аналитику и записе дебата, како би одлуке постигнуте консензусом и историја дебата биле проверљиве; осигурава високу доступност слоја података.
- **Redis** — изабран за кеширање ниске латенције и управљање редовима задатака; покреће и кеширање одговора и семантички кеш слој који омогућава да се поновљени или готово идентични упити прескоче како би се избегло сувишно закључивање.
- **LLMsVerifier (интегрисан)** — изабран да поузданост провајдера буде мерљива величина, а не претпоставка; његови резултати рангирају провајдере за рутирање и покрећу резервне опције када неки од њих почне да губи на квалитету.
- **Prometheus + Grafana + OpenTelemetry** — изабрани како би ансамбл који обухвата више провајдера остао уочљив; излажу helixagent_* метрике, контролне табле и праћење захтева од краја до краја током распршивања.
- **Model Context Protocol (MCP) адаптери** — изабрани због проширивости кроз отворени протокол; у РЕАДМЕ фајлу наведено је много MCP адаптера за повезивање спољашњих алата и контекста.

- **Neo4j / ClickHouse / Kafka (БигДата)** — изабрани да би се превазишао оквир једног чвора: Neo4j и ClickHouse подржавају дистрибуирану меморију и функције знања-графа, а Kafka стримује те графове и податке о догађајима на великој скали.
- **Интегрисане оптимизације (SGLang, LlamaIndex, LangChain, Гуиданце, LMQl)** — изабране да би се као опционе услуге додали кеширање префикса, преузимање, декомпозиција задатака и генерисање са ограничењима, тако да напредније оптимизације буду доступне, али не и обавезне.

Напомене о статусу и искрености

- **Статус: бета.** Сервис је описан као спреман за продукцију, али су перформансе и подаци о покривености наведени у РЕАДМЕ фајлу (нпр. „1000+ захтева у секунди“, „<500 мс са кешом“, број провајдера и скрипти за валидацију) само тврдње пројекта, нису независно потврђени и овде су намерно задржани у квалитативном облику.
- Број провајдера варира у самом РЕАДМЕ фајлу; страница користи квалитативни оквир „многи провајдери“.

Приоритетни ниво: Helix-primary.