

VisionEngine

像用户一样观察 UI —— 结合计算机视觉与 LLM 视觉进行分析与导航

概要

VisionEngine 是一个解耦的 Go 工具包，融合了经典计算机视觉与基于 LLM 的视觉技术，用于分析用户界面、检测 UI 元素及视觉问题，并构建应用屏幕转换的导航图谱。其多后端视觉提供程序可插拔，且 OpenCV 依赖通过构建标签隔离。

简要说明

一个可复用的 Go 模块，用于 UI 分析与导航图谱构建。提供分析层（UI 元素、屏幕差异、视觉问题）、带 BFS 路径查找的导航图谱（支持 DOT/JSON/Mermaid 导出），以及针对 GPT-4o、Claude、Gemini、Qwen-VL 等的 LLM 视觉适配器。

详细说明

大多数 UI 自动化测试实际上是“盲目”的。它们依赖无障碍树和 DOM 选择器——即机器眼中的界面——却忽略了人类真正感知的一切：按钮是否可见渲染、布局是否崩溃、跳转后的屏幕是否符合预期。VisionEngine 弥合了这一鸿沟，赋予自动化真正的感知能力，使其能像人类一样观察并理解 UI。该工具包由四个协同层次构成，从原始像素逐步构建至整个应用的理解：

分析器 (Analyzer) 定义了稳定的契约——包括接口 (Analyzer、VideoProcessor) 和值类型 (UIElement、ScreenAnalysis、ScreenDiff、Rect、Size、TextRegion、VisualIssue、ScreenIdentity、Action、KeyFrame)，并提供 StubAnalyzer 参考实现。用户可基于这一不变的契约检测元素、比对屏幕差异并发现视觉问题。

导航图谱 (NavigationGraph) 将视角从单一屏幕扩展至整个应用，将其建模为带有 BFS 路径查找的有向屏幕转换图，并支持三种导出后端 (DOT、JSON、Mermaid)。这使自动化不仅能“看见”单个屏幕，还能规划通往任意目标的路径。同时，工具包内置压力测试、自动化测试、集成测试及安全测试套件，验证其有效性。

LLM 视觉层 增强了现代多模态推理能力：通过 VisionProvider 接口，集成了 OpenAI (GPT-4o)、Anthropic (Claude)、Gemini、Qwen-VL、Kimi、StepGUI、Astica 及 Ollama 等适配器。这些适配器通过 FallbackChain 组合，确保在某个提供程序失效、限流或能力不足时，能优雅降级至下一个，避免拖垮整个运行流程。

配置层 负责环境变量加载与验证，所有面向用户的错误信息均通过 i18n.Translator 处理。

让这一切真正可落地的关键在于：重型原生依赖是可选的。OpenCV 绑定通过构建标签 -tags vision 隔离，默认构建版本仅提供占位实现。这意味着整个模块可在任何 Go 1.25+ 环境下编译、测试和运行，无需 OpenCV 工具链，仅在用户明确选择时才引入原生依赖。这一设计使 VisionEngine 能轻松集成至普通 CI 环境，无需定制镜像。

完全遵循解耦原则 (CONST-051(B))，VisionEngine 以同代码库子模块的形式被集成（如 HelixQA），为基于证据的 UI 测试提供了一双真正的“眼睛”。

为何构建

仅依赖无障碍树或选择器的 UI 自动化测试，无法捕捉用户实际看到的内容。VisionEngine 增加了真正的视觉理解能力——元素检测、屏幕对比以及 LLM 视觉推理，并提供可导航的应用界面地图，使自动化既能感知 UI，又能在其中规划路径。

为何是颠覆性变革

它将两种通常互不兼容的方法——快速、确定性的经典计算机视觉与灵活、语义化的 LLM 视觉——整合于同一接口之下，并通过回退链机制，让用户无需取舍，即可同时获得前者的精准与后者的推理能力。此外，通过严格将 OpenCV 设为可选项，它消除了通常与之相伴的性能代价：任何 Go 项目均可获得真正的 UI 感知能力，而无需在构建中引入原生视觉工具链。

创新之处

- 双重感知：经典计算机视觉 (OpenCV/GoCV) 与多提供商 LLM 视觉，配备回退链。
- 导航图谱：支持广度优先搜索 (BFS) 路径规划，并可导出 DOT/JSON/Mermaid 格式。
- 构建标签门控 **OpenCV**：通过构建标签控制，确保模块在无原生依赖的情况下仍可构建与测试。
- 完全解耦、国际化接缝、代码库统一的子模块（由 HelixQA 使用）。

挑战与解决方案

- 原生依赖冲突：通过 `-tags vision` 标签门控及默认存根解决，确保无 OpenCV 的 CI/主机环境仍可正常构建与测试。
- 视觉提供商不稳定：通过 VisionProvider 接口与 FallbackChain 组合器解决。
- 复杂应用流程映射：通过有向导航图谱、BFS 路径规划及多格式导出解决。
- 耦合问题：通过 CONST-051(B) 解耦方案及国际化翻译层解决。

技术栈（选择与实现）

- **Go (1.25+)**：模块核心及全部四层架构。
- **GoCV / OpenCV**：经典计算机视觉，通过构建标签门控。
- **LLM 视觉提供商 (GPT-4o、Claude、Gemini、Qwen-VL、Kimi、StepGUI、Astica、Ollama)**：通过适配器实现多模态 UI 推理。
- **图算法 (BFS)**：导航路径规划。
- **DOT / JSON / Mermaid** 导出器：导航图谱可视化。
- **国际化翻译层**：解耦用户界面字符串。