

बायोडाटा



Miloš Vasić

AI इंजीनियर · सॉफ्टवेयर इंजीनियर

LLM बुनियादी ढाँचा, स्वायत्त एजेंट, और वह शासन-व्यवस्था जो उन्हें विश्वसनीय बनाती है। एकल संरचनाओं के बजाय बेड़े; धोखाधड़ी-मुक्त, साक्ष्य-आधारित गुणवत्ता।

2009

इंजीनियरिंग का अनुभव

140+

शासित रिपॉजिटरीज़

43

LLM प्रदाताओं का एकीकरण

6+

मुख्य भाषाएँ

इंजीनियर — LLM अवसंरचना, स्वायत्त एजेंट और उनको विश्वसनीय बनाने वाली शासन प्रणाली।

- ईमेल: milos85vasic@gmail.com
- वेब: <https://milosvasic.ru> · <https://vasic.digital>
- GitHub: vasic-digital · HelixDevelopment · Server-Factory

सारांश

AI/सॉफ्टवेयर इंजीनियर जो एंड-टू-एंड AI-विकास प्रणालियाँ बनाता हूँ — मल्टी-प्रोवाइडर LLM अवसंरचना और स्वायत्त एजेंटों से लेकर उनको ईमानदार बनाए रखने वाली क्यूए और शासन परतों तक। मैं डेमो नहीं, प्लेटफ़ॉर्म डिलीवर करता हूँ। 15 वर्षों से अधिक का पेशेवर इंजीनियरिंग अनुभव (2009 से) मोबाइल एसडीके, रियल-टाइम हार्डवेयर इंटीग्रेशन और डिस्ट्रिब्यूटेड बैकएंड पर काम करते हुए अब एक ही फोकस पर केंद्रित है: स्वायत्त AI विकास को बड़े पैमाने पर विश्वसनीय बनाना।

मैं मोनोलिथ नहीं, फ़्लिट्स का आर्किटेक्चर करता हूँ — दर्जनों छोटे, डिक्पल्ड, स्वतंत्र रूप से टेस्टेड मॉड्यूल्स पर खड़ी बड़ी उत्पाद एप्लिकेशन, जिनमें से हर एक साझा इंजीनियरिंग Constitution को इनहेरिट करता है और एक एंटी-ब्लफ़, एविडेंस-गेटेड क्यूए अनुशासन द्वारा सत्यापित होता है। प्राथमिक भाषा Go, साथ में Kotlin/KMP, TypeScript/React, Python, Swift, और Shell। मार्गदर्शक सिद्धांत, जिसे केवल कहा नहीं बल्कि यांत्रिक रूप से लागू किया जाता है: कोई फीचर तब तक पूरा नहीं माना जाता जब तक कोई वास्तविक उपयोगकर्ता उसका इस्तेमाल न कर सके और उसका प्रमाणित सबूत न हो।

मेरी विशेषता: एक AI क्षमता को शोध विचार से शासित, आत्म-सत्यापित, प्रोडक्शन-तैयार प्रणाली में बदलने की क्षमता — LLM रूटिंग जो हर मॉडल को भरोसे से पहले उसके काम करने का प्रमाण देती है, एजेंट जो अनुमान लगाने के बजाय बहस करके सहमति बनाते हैं, मेमोरी और RAG परतें जो संदर्भ नहीं खोतीं, और एक ऐसा पूरा इकोसिस्टम जिसमें “टेस्ट पास हो गए” का मतलब कभी चुपचाप “फीचर टूटा हुआ है” न हो।

मुख्य दक्षताएँ

- **AI / LLM सिस्टम:** मल्टी-प्रोवाइडर LLM एब्सट्रैक्शन (40+ प्रोवाइडर), MCP टूल इंटीग्रेशन, RAG, vector डेटाबेस और embeddings, एजेंट ऑर्केस्ट्रेशन (हेडलेस CLI एजेंट, ग्राफ वर्कफ़्लो, बहु-चरणीय बहस/सहमति), प्लानिंग (HiPlan/MCTS/ट्री-ऑफ़-थॉट्स), LLM Ops, बेंचमार्किंग (SWE-bench/HumanEval/MMLU), LLM सत्यापन, डिफ़ेंसिव-LLM गार्डरेल्स, कंप्यूटर-विज्ञान + LLM-विज्ञान।
- **बैकएंड इंजीनियरिंग:** Go (Gin), gRPC + Protobuf, HTTP/3 (QUIC), वेबसॉकेट, डिस्ट्रिब्यूटेड सिस्टम (TLA+ औपचारिक स्पेसिफिकेशन सहित), हाई-थ्रूपुट REST सेवाएँ और समवर्ती वर्कर।
- **डेटा:** PostgreSQL, SQLite, SQLCipher (एन्क्रिप्शन एट रेस्ट), Redis, Neo4j, ClickHouse, ऑब्जेक्ट स्टोरेज (MinIO/S3/GCS/Azure)।
- **फ्रंटएंड / क्रॉस-प्लेटफ़ॉर्म:** TypeScript/React (टेलविंड, रिडक्स टूलकिट, i18next), Angular, Electron, React Native, Kotlin Multiplatform, एंड्रॉयड/एंड्रॉयड टीवी (Kotlin), आईओएस (Swift), Tauri/Rust।
- **इन्फ्रा / डेवऑप्स:** Docker और कंपोज़, Kubernetes + Helm, Prometheus + Grafana, OpenTelemetry, QEMU/Libvirt/Parallels; CI/CD via GitHub Actions, Gradle, Make।

- **क्यूए / गुणवत्ता इंजीनियरिंग:** एंटी-ब्लफ़ एविडेंस-गेटेड क्यूए (HelixQA), म्यूटेशन गेट्स वाले चैलेंज हार्नेस, `go test -race`, विज़ुअल-रिग्रेसन टेस्टिंग, एडीबी डिवाइस टेस्टिंग, SonarQube, सुरक्षा स्कैनिंग (semgrep/gosec/trivy/snyk/gitleaks/nancy)।
- **इंजीनियरिंग शासन:** Constitution-एज़-सबमॉड्यूल; इनहेरिटेस और प्रोपेगेशन गेट्स; 140+ रिपॉजिटरी के फ़्लैट में दस्तावेज़ीकरण/कवरेज अनुशासन।

चयनित परियोजनाएँ

शासन और गुणवत्ता आश्वासन

- **HelixConstitution** — एक सार्वभौमिक इंजीनियरिंग नियमपुस्तिका, जिसे गिट सबमॉड्यूल के रूप में वितरित किया जाता है और 140 से अधिक रिपॉजिटरीज़ में विरासत में प्राप्त किया जाता है: इंजीनियरिंग कानून को ठीक वैसे ही शिप और वर्जन-पिन किया जाता है जैसे कोड। एक सबमॉड्यूल अपडेट पूरे बेड़े के नियमों को अपग्रेड कर देता है, और प्रसार गेट्स सचमुच हर उपभोग करने वाले रिपॉजिटरी में आवश्यक क्लॉज़ के लिए ग्रेप करते हैं — हर गेट के साथ एक म्यूटेशन मेटा-टेस्ट जुड़ा होता है जो साबित करता है कि गेट खुद कोई धोखा नहीं है। यह “सर्वोत्तम प्रथाओं जिनका लोग पालन करने की उम्मीद करते हैं” को विरासत में मिलने वाले, ऑडिट योग्य, यांत्रिक रूप से लागू किए जाने वाले एंटी-ब्लफ़ कानून में बदल देता है।
- **HelixQA** — एंटी-ब्लफ़ गुणवत्ता आश्वासन ऑर्केस्ट्रेशन (Go), जो एक अडिग नियम पर आधारित है: मानक यह नहीं है कि “टेस्ट पास हो जाएँ” बल्कि यह कि “उपयोगकर्ता सुविधा का उपयोग कर सकें।” यह लिखित YAML टेस्ट बैंक चलाता है और पूरी तरह स्वायत्त LLM-एंड-विज़न QA सत्र, जो वास्तविक ऐप खोलते हैं, हर दस्तावेज़ीकृत सुविधा की पुष्टि करते हैं, Android/Android TV/वेब/डेस्कटॉप पर अनदस्तावेज़ीकृत बग्स की खोज करते हैं, और बिना कैप्चर किए गए रनटाइम प्रमाण — स्क्रीनशॉट, लॉगकैट, वीडियो, स्टैक ट्रेस — तथा AI-फिक्स-तैयार टिकट के, PASS स्कोर देने से इनकार करते हैं।

AI विकास और LLM अवसंरचना

- **HelixAgent** — प्रोडक्शन-ग्रेड एन्सेम्बल LLM सेवा (Go/Gin), जो किसी एक मॉडल पर भरोसा नहीं करती: यह एक प्रॉम्प्ट को कई प्रदाताओं में फैलाती है, संरचित बहु-चरणीय बहस (प्रस्ताव → आलोचना → समीक्षा → संश्लेषण) चलाती है, और लाइव वेरिफिकेशन स्कोर के आधार पर रूटिंग करती है, जिसमें ग्रेसफुल फॉलबैक होता है — सब कुछ OpenAI-संगत API के पीछे, जिसमें HA डेटा लेयर, ऑब्ज़र्वेबिलिटी और गार्डरेल्स शामिल हैं। *Go, Gin, PostgreSQL, Redis, Prometheus/Grafana/OpenTelemetry, MCP, Neo4j/ClickHouse/Kafka*
- **HelixCode** — वितरित AI विकास प्लेटफ़ॉर्म, जो काम को SSH-प्रबंधित वर्कर फ़्लैट में बुद्धिमान, निर्भरता-जागरूक कार्यों में विभाजित करता है, फिर चेकपॉइंट और रोलबैक करता है ताकि किसी कार्य के बाधित होने पर कुछ भी नष्ट न हो; हार्डवेयर-जागरूक मॉडल चयन और पूर्ण योजना/निर्माण/परीक्षण/रिफैक्टोरिंग जीवनचक्र REST/CLI/TUI/MCP के पीछे। *Go, Gin, PostgreSQL, Redis, SSH, MCP, llama.cpp/Ollama*
- **HelixLLM** — एक बाइनरी, छह डिप्लॉयमेंट मोड: OpenAI- और Anthropic-संगत अनुमान HTTP/3 पर, जो लैपटॉप से लेकर मल्टी-होस्ट क्लस्टर तक स्केल करता है, जिसमें स्थानीय llama.cpp अनुमान (CUDA/Metal/ROCm) और एक ऑटो-डिस्कवरी, वेरिफिकेशन-स्कोर्ड क्लाउड फॉलबैक चेन शामिल है, जो हमेशा गारंटीकृत स्थानीय मॉडल पर डिग्रेड होता है। *Go, HTTP/3 QUIC, gRPC/SSE/Kafka, llama.cpp*
- **LLMProvider / LLMOrchestrator / LLMsVerifier** — LLM-अवसंरचना की रीढ़: 43 प्रदाताओं पर एक इंटरफ़ेस, जिसमें सर्किट ब्रेकर, स्वास्थ्य निगरानी, जिटर्ड-बैकऑफ़ रिट्राइज़ और ईमानदार (कोई हार्डकोडेड फॉलबैक नहीं) मॉडल डिस्कवरी शामिल है; एक ग्रेड-सेफ़ कंट्रोल प्लेन, जो हेडलेस CLI एजेंट्स (OpenCode, Claude Code, Gemini, Junie, Qwen Code) को हाइब्रिड पाइप+फ़ाइल प्रोटोकॉल पर स्पॉन और संचालित करता है; और एक वेरिफिकेशन स्रोत सत्य, जिसका अनिवार्य “क्या तुम्हें मेरा कोड दिख रहा है?” गेट यह सुनिश्चित करता है कि केवल वे मॉडल ही उपयोग योग्य या निर्यात के लिए चिह्नित किए जाते हैं, जिन्हें वास्तव में काम करते हुए साबित किया गया हो।

- **HelixMemory / HelixSpecifier** — एक एकीकृत संज्ञानात्मक-स्मृति इंजन, जो चार सर्वश्रेष्ठ बैकएंड्स (Mem0, Cognition, Letta, Graphiti) को एक इंटरफ़ेस के पीछे समाहित करता है, जिसमें समानांतर खोज और क्रॉस-सोर्स रीरैंकिंग शामिल है; और एक स्पेक-ड्रिवेन-डेवलपमेंट फ्यूज़न इंजन, जो अपने स्वयं के अनुष्ठान को कार्य के आकार के अनुसार स्केल करता है और स्पेसिफिकेशन्स को मल्टी-एजेंट बहस के साथ समर्थित करता है।
- **HelixTrack** — एक मुक्त-विश्व JIRA + Confluence विकल्प (Helix-ट्रैक लाइन का प्रमुख उत्पाद): Go माइक्रोसर्विसेज़ के साथ एकीकृत एक्शन-रूटेड API HTTP/3 पर, आराम पर SQLCipher एन्क्रिप्शन, और नेटिव वेब/डेस्कटॉप/Android/iOS क्लाइट्स के साथ।

सामग्री

उत्पाद-स्तरीय उपकरण (वैसिक-डिजिटल यूटिल्स)

- **Catalogizer** — बहु-प्रोटोकॉल, एन्क्रिप्टेड, स्व-होस्टेड मीडिया संग्रह प्रबंधन (Go/Gin + React), अस्थिर नेटवर्क स्टोरेज के प्रति लचीला, 21 पुनःप्रयोगी उप-मॉड्यूल पर निर्मित।
- **Courses-Creator** — मार्कडाउन-टू-वीडियो AI पाठ्यक्रम पाइपलाइन, जिसमें TTS और डेस्कटॉप/मोबाइल/वेब प्लेयर्स शामिल हैं।
- **VisionEngine** — कंप्यूटर-विज्ञान + बहु-प्रदाता LLM-विज्ञान यूआई धारणा, नेविगेशन ग्राफ़ के साथ।
- **DocProcessor · Docs Chain · Herald · task_bridge · Vasic Digital** पुनःप्रयोगी मॉड्यूल सूट — क्यूए फीचर-मैपिंग, कंटेंट-हैशड दस्तावेज़/डेटाबेस सिंक, प्राकृतिक-भाषा सूचनाएँ, टास्क/बोर्ड सिंक, और `digital.vasic.*` मानक-लाइब्रेरी समूह।

इंफ्रास्ट्रक्चर ऑटोमेशन (Server Factory)

- **Mail Server Factory** — घोषणात्मक JSON → 12 कनेक्शन प्रकारों और 25 लिनक्स वितरणों पर पूरी तरह से प्रोविज़नड, डॉकराइज़्ड मेल सर्वर; 439 पासिंग टेस्ट और एक स्वच्छ SonarQube गेट रिपोर्ट करता है।
- **Server Factory** कोर फ्रेमवर्क, **Qemu-Utils**, **Parallels-Utils** — साझा प्रोविज़निंग इंजन और वीएम-इमेज टूलिंग।

भाषाएँ और उपकरण (संक्षिप्त सूची)

Go · Kotlin · Kotlin Multiplatform · TypeScript · JavaScript · Python · Swift · Java · Rust · Shell · PL/pgSQL · TLA+ · Gin · gRPC · HTTP/3 · React · Angular · Electron · React Native · PostgreSQL · SQLite · SQLCipher · Redis · Neo4j · ClickHouse · Docker · Kubernetes · Prometheus · Grafana · OpenTelemetry · QEMU · GitHub Actions · Gradle · Make

अनुभव

2009 से सॉफ्टवेयर इंजीनियर, संपूर्ण विकास चक्र में — योजना, विकास, टीम लीडिंग और डिप्लॉयमेंट। नीचे दिया गया पूरा इतिहास उम्मीदवार के सत्यापित रिकॉर्ड (milosvasic.ru) से लिया गया है।

पूर्णकालिक पद

- **SDK डेवलपर — Harness** (harness.io), बेलग्रेड, सर्बिया · 03/2020 – 12/2024। कंपनी के फीचर फ्लैग डिवीज़न के लिए SDK परिवार पर लीड डेवलपर, सभी प्रमुख मोबाइल प्लेटफॉर्म और उससे आगे पर केंद्रित। ग्राहकों और साझेदारों में AWS, Google और विभिन्न बैंक शामिल थे। तकनीक: *Android, iOS, Flutter, React Native, TypeScript, JavaScript, Java, Kotlin, Swift, Go, Ruby*

- सॉफ्टवेयर इंजीनियर — **Leica Geosystems** (leica-geosystems.com), हेरब्रुग, स्विट्ज़रलैंड · 02/2016 – 02/2020। मुख्य रूप से Leica Geosystems के अत्याधुनिक 3D स्कैनर्स के लिए iOS और Android इंजीनियरिंग — हार्डवेयर के साथ रीयल-टाइम संचार, डेटा प्रोसेसिंग और सिंक्रोनाइज़ेशन। साझेदार: Autodesk। तकनीक: *Android, iOS, Java, Kotlin, Swift, C++*।
- **SDK डेवलपर** — **Bosch** (bosch.rs), बेलग्रेड, सर्बिया · 01/2010 – 01/2016। कनेक्टेड व्हीकल्स SDK प्रोजेक्ट के लिए लीड SDK डेवलपर — OBD2 बस के साथ रीयल-टाइम Bluetooth संचार, उच्च-प्रदर्शन डेटा प्रोसेसिंग और दृढ़ता। तकनीक: *Android, Java, Kotlin*।

सामग्री

अन्य कार्यभार

- **TN-TECH** (tn-tech.co.rs), नोवी साद, सर्बिया · अंशकालिक, मार्च २०१७ से। ग्लोबेक्स डेटा (कनाडा और स्विट्ज़रलैंड) के लिए कार्य — सेकुर (सेकुरमैसेंजर), सेकुरमेल, सेकुरसूट — तथा बसराइड प्लेटफॉर्म। तकनीक: एंड्रॉयड, जावा, *Kotlin, C++*, क्यूटी।
- **Increment Loop** (incrementloop.com), बेलग्रेड, सर्बिया · अंशकालिक, सितंबर २०२३ से। यूनो एप्लिकेशन। तकनीक: एंड्रॉयड, *Kotlin*।
- ओपन-सोर्स / स्वयं के संगठन — HelixTrack, Server Factory (Mail Server Factory, Parallels-Utils, Qemu-Utils), तथा Vasic Digital (एंड्रॉयड-टूलकिट, नेटवर्क-बाइंडर), जिनका विस्तृत विवरण ऊपर “चयनित परियोजनाएँ” के अंतर्गत दिया गया है।

प्रकाशन

- मौलिक **Kotlin** — स्व-प्रकाशित लेखक; नवीनतम संशोधित संस्करण सितंबर २०२२ (मौलिक Kotlin, तीसरा संस्करण)। इसके अतिरिक्त Packt पब्लिशिंग (यूके) के लिए भी लेखन किया।

शिक्षा

- एम.एससी, समकालीन सूचना प्रौद्योगिकी — विश्वविद्यालय Singidunum, बेलग्रेड, सर्बिया · २०१४।
- बी.एससी, सूचना विज्ञान एवं संगणन — विश्वविद्यालय Singidunum, बेलग्रेड, सर्बिया · २००८।